

Universidad de Salamanca
Grado en Física



4^º FÍSICA

TRABAJO FIN DE GRADO DEL
GRADO EN FÍSICA

Algoritmos de simulación
Montecarlo en el modelo de Ising

Pablo López Serna
Tutor: Antonio González Sánchez

Curso 2025/2026

Universidad de Salamanca
Grado en Física



4^º FÍSICA

TRABAJO FIN DE GRADO DEL
GRADO EN FÍSICA

Algoritmos de simulación
Montecarlo en el modelo de Ising

Pablo López Serna
Tutor: Antonio González Sánchez

Curso 2025/2026

Firma del autor:

Fdo.: Pablo López Serna

Resumen

El modelo de Ising es, desde casi su concepción, uno de los sistemas más importantes de estudio en la mecánica estadística. Esto es debido a que desde su increíble simplicidad, es capaz de presentar una amplia gama de fenómenos distintos y relevantes, como la transición de fase ferromagnética-paramagnética de un material 2D, la divergencia de la longitud de correlación en la temperatura crítica T_c o el ciclo de histéresis magnética; y propiedades como la clase de universalidad y la existencia de exponentes críticos correspondientes a esta.

En este trabajo se estudia el modelo bidimensional mediante el método de Montecarlo, usando y comparando tres algoritmos distintos: Metropolis, Glauber y Wolff. La motivación detrás de implementar más de un algoritmo es que cada uno tiene sus puntos negativos y positivos, por lo que se hace un estudio comparativo para diferenciar bajo qué circunstancias resultan mejores unos u otros.

Las simulaciones se realizan sobre una red cuadrada de lados $L \in \{16, 32, 64, 128\}$ con condiciones de contorno periódicas, tomando el acoplamiento magnético como $J = 1$ y la temperatura en unidades de J/k_B . Para cada tamaño, temperatura y red se recogen suficientes muestras tras un período de termalización como para intentar calcular con precisión las magnitudes buscadas. Entre los observables calculados se encuentran la magnetización media por partícula $\langle |m| \rangle$, la capacidad calorífica C , la susceptibilidad magnética χ , el cumulante de cuarto orden de Binder U_4 y la longitud de correlación de segundo momento ξ_L .

Para el estudio de los exponentes críticos se hace uso de la técnica del escalado de tamaño finito (*Finite Size Scaling*, FSS): si los datos se reescalan adecuadamente usando las potencias de L usando los exponentes críticos, la teoría dice que las curvas de distintos tamaños deberían colapsar unas sobre las otras. Se ajustan los exponentes para encontrar el colapso de los datos de manera visual, y con ello los valores aproximados de los exponentes críticos obtenidos con nuestra simulación. Este colapso se comprueba para la susceptibilidad magnética y la longitud de correlación.

El cumulante de Binder ya es una magnitud escalada, y tiene la propiedad de que las curvas para distintos tamaños se cortan aproximadamente en la temperatura crítica, lo que permite obtener un resultado sin la necesidad de ajustar exponentes. Sin embargo, aún así implementamos un segundo método de cálculo de la temperatura crítica usando el cumulante de Binder, para intentar eliminar los posibles efectos de tamaño finito.

El otro aspecto relevante del trabajo es la comparación entre los tres algoritmos utilizados. El tiempo de autocorrelación integrado τ_{int} , calculado mediante el estimador de ventana de Madras–Sokal (Madras y Sokal, 1988), muestra que Metropolis y Glauber sufren un fenómeno conocido como *critical slowing down*: se necesitan muchas más medidas independientes cerca de T_c para obtener un resultado significativo, algo característico de las dinámicas locales. Cabe destacar que Glauber sufre más este fenómeno que Metropolis, lo que nos permite ver las diferencias entre los mecanismos de actualización de ambas. Wolff es lo que se conoce como un algoritmo de *cúmulo*, que elimina este fenómeno: τ_{int} de Wolff es muy bajo y no tiene estructura en todo el rango de temperaturas analizado.

Los resultados obtenidos son satisfactorios al compararlos con lo predicho por la teoría, desde los exponentes y la temperatura crítica de Onsager a la distinción entre diferentes algoritmos en magnitudes como el tiempo o la longitud de correlación.

Palabras clave: modelo de Ising, Monte Carlo, Metropolis, Glauber, Wolff, transición de fase, escalado de tamaño finito, exponentes críticos, temperatura crítica, *critical slowing down*.

Abstract

The Ising model has been, almost since its conception, one of the most important systems of study in statistical mechanics. This is due to the fact that, from its incredible simplicity, it is capable of presenting a wide range of different and relevant phenomena, such as the ferromagnetic-paramagnetic phase transition of a 2D material, the divergence of the correlation length at the critical temperature T_c , the universality class and the existence of critical exponents, or the magnetic hysteresis cycle.

In this work the two-dimensional model is studied using the Monte Carlo method, implementing and comparing three different algorithms: Metropolis, Glauber and Wolff. The motivation behind implementing more than one algorithm is that each one has its own drawbacks and advantages, so a comparative study is carried out to differentiate under which circumstances each one performs better.

The simulations are performed on square lattices with side lengths $L \in \{16, 32, 64, 128\}$ with periodic boundary conditions, using the magnetic coupling $J = 1$ and temperature in units of J/k_B . For each size, temperature and lattice, enough samples are collected after a thermalisation period in order to attempt to calculate the target quantities with sufficient precision. Among the computed observables are the mean magnetisation per spin $\langle|m|\rangle$, the heat capacity C , the magnetic susceptibility χ , the fourth-order Binder cumulant U_4 , and the second-moment correlation length ξ_L .

To study the critical exponents, the Finite Size Scaling (FSS) technique is employed: if the data are appropriately rescaled using powers of L with the critical exponents, theory predicts that the curves for different system sizes should collapse onto one another. The exponents are fitted to find the data collapse visually, thereby obtaining approximate values of the critical exponents from our simulation. This collapse is verified for both the magnetic susceptibility and the correlation length.

The Binder cumulant is already a scaled quantity, and has the property that curves for different system sizes cross approximately at the critical temperature, which allows one to obtain a result without the need to fit any exponents. Nevertheless, we also implement a second method for computing the critical temperature using the Binder cumulant, in order to attempt to eliminate possible finite-size effects.

The other relevant aspect of the work is the comparison between the different algorithms used. The integrated autocorrelation time τ_{int} , computed using the Madras–Sokal windowing estimator (Madras y Sokal, 1988), shows that Metropolis and Glauber suffer from a phenomenon known as critical slowing down: many more independent measurements are needed near T_c to obtain a meaningful result, which is characteristic of local dynamics. It is worth noting that Glauber suffers more from this phenomenon than Metropolis, which allows us to observe the differences between the update mechanisms of both. Wolff is what is known as a cluster algorithm, which eliminates this phenomenon: the τ_{int} of Wolff is very low and has no structure across the entire analysed temperature range. The results obtained are satisfactory when compared with theoretical predictions, from Onsager’s critical exponents and critical temperature to the distinction between different algorithms in quantities such as the autocorrelation time or the correlation length.

Keywords: Ising model, Monte Carlo, Metropolis, Glauber, Wolff, phase transition, finite size scaling, critical exponents, critical temperature, critical slowing down.

Índice general

1. Introducción	1
1.1. Motivación	1
1.2. Objetivos	2
2. Fundamento teórico	3
2.1. Modelo de Ising	3
2.2. Mecánica estadística	4
2.3. Transición de fase, temperatura crítica y exponentes críticos	6
2.4. Escalado de tamaño finito	7
2.5. Tiempo de correlación	7
3. Modelo y métodos	10
3.1. El modelo simulado	10
3.2. Definición del paso Montecarlo	10
3.2.1. Condiciones de contorno	11
3.3. Configuración inicial y termalización	11
3.4. Vector de temperaturas	12
3.5. Parámetros de la simulación	12
3.6. Métodos de Montecarlo	13
3.6.1. Algoritmo de Metropolis	13
3.6.2. Dinámica de Glauber	14
3.6.3. Algoritmo de Wolff	14
3.7. Observables medidos	15
3.8. Análisis de escalado de tamaño finito	16
4. Resultados y discusión	17
4.1. Capacidad calorífica y magnetización	17
4.2. Cumulante de Binder	20
4.3. Susceptibilidad magnética	20
4.4. Escalado de tamaño finito de la susceptibilidad	20
4.5. Longitud de correlación	22
4.5.1. Colapso de datos de la longitud de correlación	24
4.6. Tiempo de autocorrelación	28
5. Conclusiones	32

Capítulo 1

Introducción

1.1. Motivación

El estudio de las transiciones de fase es uno de los problemas principales de la física estadística. Una transición de fase ocurre cuando un sistema experimenta un cambio en sus propiedades macroscópicas al variar algún parámetro o efecto externo, como puede ser la temperatura. Estas se clasifican según el comportamiento de la energía libre y sus derivadas (Stanley, 1971): en las de primer orden hay una discontinuidad en la primera derivada, lo que da lugar a calor latente y coexistencia de fases, mientras que en las de segundo orden (o continuas) la primera derivada es continua y es la segunda la que diverge. En este trabajo nos vamos a centrar en una transición de segundo orden, donde el modelo de Ising resulta particularmente relevante.

El modelo de Ising fue propuesto por Wilhelm Lenz en 1920 como un modelo sencillo para tratar de explicar el ferromagnetismo a su estudiante doctoral Ernst Ising, quien consiguió resolverlo analíticamente en dimensión $D = 1$ en 1925 (Ising, 1925). La solución que obtuvo fue, en cierto modo, decepcionante: en una dimensión no aparecía ninguna transición de fase. Esto llevó a Ising a concluir, erróneamente, que tampoco la habría en dimensiones superiores, y que el modelo no podría reproducir los fenómenos observados experimentalmente.

Hubo que esperar hasta 1944 para que Lars Onsager, con un cálculo de notable dificultad técnica, resolviera el modelo en dos dimensiones (Onsager, 1944). Con ello demostró que el modelo sí presentaba una transición de fase de segundo orden a temperatura finita (Peierls, 1936), de un estado ferromagnético a uno paramagnético, junto con los ingredientes y resultados característicos de este tipo de transiciones. Desde entonces el modelo se ha convertido en uno de los pilares de la mecánica estadística, precisamente por ser lo bastante sencillo como para admitir un tratamiento exacto y, a la vez, lo bastante rico como para mostrar un comportamiento complejo.

En ausencia de campo magnético externo, el Hamiltoniano del modelo es

$$\mathcal{H} = -J \sum_{\langle i,j \rangle} \sigma_i \sigma_j, \quad (1.1)$$

con los espines $\sigma_i = \pm 1$ situados en los nodos de una red cuadrada, la suma extendida a los pares de primeros vecinos y $J > 0$ en el caso ferromagnético. Para la red cuadrada

bidimensional, la solución de Onsager da también el valor exacto de la temperatura crítica,

$$T_c = \frac{2J}{k_B \ln(1 + \sqrt{2})} \approx 2,2692 \frac{J}{k_B}, \quad (1.2)$$

valor que se usará más adelante como referencia para los resultados de la simulación. Es justamente esta solución exacta lo que convierte al modelo en un sistema de prueba para algoritmos de simulación: si un método no es capaz de reproducir estos resultados aquí, no va a ser fiable en problemas donde no haya nada con lo que comparar.

Desde entonces, el modelo ha sido utilizado para tratar de modelar o explicar comportamientos en áreas realmente diversas y muy alejadas de su propósito original, desde la biología hasta las finanzas. Dado este interés en su aplicación, en este estudio se explican y desarrollan las principales técnicas de simulación que existen para obtener soluciones numéricas del modelo mediante simulaciones Montecarlo, los parámetros o valores de interés que se pueden extraer de ellas, y una comparativa de las ventajas e inconvenientes de cada una de las técnicas empleadas.

1.2. Objetivos

El objetivo del trabajo es la comparación completa de tres de los algoritmos más utilizados en simulaciones Montecarlo, aplicados al modelo de Ising bidimensional en red cuadrada y sin campo magnético externo, para tamaños de red $L \in \{16, 32, 64, 128\}$. Para ello se desarrollan tres programas en Fortran que implementan los algoritmos de Metropolis (Metropolis et al., 1953), Glauber (Glauber, 1963) y Wolff (Wolff, 1989). Para comprobar que los tres funcionan correctamente y poder compararlos entre sí, con las simulaciones se calculan las magnitudes más relevantes del sistema: la magnetización media $\langle |m| \rangle$, la capacidad calorífica por partícula c (de aquí en adelante, toda referencia a capacidad calorífica será por partícula aunque no se indique explícitamente), la susceptibilidad magnética χ , el cumulante de Binder U_4 y la longitud de correlación ξ_L . Todo esto se hace mediante un barrido de temperaturas y de tamaños de red.

El barrido en temperaturas sirve para estudiar con más detalle el comportamiento del sistema en torno a la transición de fase, que ocurre alrededor de la llamada temperatura crítica T_c (cuyo valor exacto según Onsager es $T_c \approx 2,2692 J/k_B$, ecuación (1.2)) para cada una de las magnitudes estudiadas. El barrido en tamaños, por su parte, permite varias cosas: ver cómo dependen las magnitudes del tamaño de la red para aproximar su valor en el límite de tamaño infinito u obtener los exponentes críticos asociados a la clase de universalidad del modelo de Ising aplicando la técnica del escalado de tamaño finito.

Finalmente, se mide también el tiempo de autocorrelación integrado. Esto no es una magnitud física del sistema propiamente dicho, sino una cantidad asociada a la propia simulación, y permite una comparación adicional entre los tres algoritmos, sobre todo en términos de su eficiencia cerca del punto crítico.

Estructura de la memoria

La memoria se organiza como sigue. El capítulo 2 recoge el fundamento teórico necesario para entender el modelo, la transición de fase que presenta y el método Montecarlo, incluyendo la explicación de los tres algoritmos empleados. El capítulo 3 describe el modelo simulado y los parámetros de la simulación. Los resultados se presentan y discuten en el capítulo 4, y las conclusiones en el capítulo 5.

Capítulo 2

Fundamento teórico

En este primer capítulo se explican los fundamentos teóricos necesarios para poder desarrollar e interpretar las simulaciones del resto del trabajo. Antes de entrar en el método Montecarlo y los algoritmos usados, conviene precisar el sistema de estudio y con qué magnitudes se describe. Partiendo del origen físico del ferromagnetismo y de la transición de fase ferromagnética-paramagnética, se formaliza el modelo de Ising y su hamiltoniano, se introducen los observables relevantes y, para terminar, repasamos los conceptos (exponentes críticos, escalado de tamaño finito, tiempo de correlación), sobre los que se sustenta el análisis de los resultados obtenidos.

Un sistema ferromagnético se define por el ordenamiento en una misma dirección y sentido de los espines que lo conforman, dando así una magnetización macroscópica no nula al sumarse todas las contribuciones. Este ordenamiento se ve roto por la energía térmica del sistema: cuando esta no es suficiente para desordenar los espines, estos son capaces de mantenerse orientados, y cuando sí lo es, dejan de estarlo. De aquí surge de manera natural el concepto de temperatura crítica, que marca el punto en el que ocurre la transición de fase en función de la energía térmica del sistema. Esta transición ocurre idealmente de manera abrupta y a una temperatura finita exacta, pero debido al tamaño limitado de nuestro sistema esto no se observa así, sino que cuanto mayor es el tamaño más se aproxima al salto ideal.

Un sistema real tiene un número altísimo de componentes, y lo vamos a tratar como si estuviese en contacto con un foco térmico que varía su temperatura de manera infinitamente lenta, por lo que resulta natural describirlo mediante la colectividad canónica de la física estadística. En esta sección se revisa una descripción general de la colectividad canónica, y se derivan las expresiones necesarias para calcular los observables físicos relevantes para el sistema en estudio. Además, se define formalmente el modelo de Ising, su hamiltoniano, las aproximaciones tomadas, las condiciones de contorno utilizadas y los algoritmos implementados para su estudio.

2.1. Modelo de Ising

Procedemos con una definición completa del modelo de Ising. Este consiste en una red bidimensional cuadrada de puntos equiespaciados, en cada uno de los cuales se sitúa un espín que puede tomar dos valores discretos: $+1$ o -1 . En general, el hamiltoniano de un sistema de este tipo es

$$\mathcal{H} = -J \sum_{\langle i,j \rangle} s_i s_j - H \sum_i s_i,$$




Figura 2.1: Ejemplo de un segmento de red del modelo de Ising bidimensional. *Fuente.*

donde $s_i = \pm 1$ es la variable de espín situada en el nodo i de la red, J es la constante de acoplamiento que relaciona la interacción entre espines con la energía y H es un campo magnético externo uniforme acoplado a cada espín. Las dos sumas se extienden, respectivamente, a los pares de espines primeros vecinos de cada nodo y a todos los espines de la red.

Si $J > 0$, el estado de mínima energía del hamiltoniano corresponde a un alineamiento de todos los espines, por lo que se trata de un material ferromagnético. Si en su lugar $J < 0$, el estado de mínima energía corresponde a alineamientos en la misma dirección pero sentidos contrarios, dando lugar al antiferromagnetismo. En este trabajo se va a tratar el modelo de Ising en ausencia de campo magnético, por lo que $H = 0$ y el hamiltoniano del sistema se simplifica a la interacción magnética entre espines, $\mathcal{H} = -J \sum_{\langle i,j \rangle} s_i s_j$, restringida ya a primeros vecinos.

El parámetro de orden natural para esta transición es la magnetización por espín, $m = \frac{1}{N} \sum_i s_i$, donde $N = L^2$ es el número total de espines de la red. En el límite termodinámico, $m = 0$ a temperaturas mayores a T_c y $m \neq 0$ por debajo, indicando el paso del estado paramagnético al ferromagnético. En un sistema finito, sin embargo, la simetría del hamiltoniano frente a la inversión global de todos los espines hace que el promedio de la magnetización por espín sea $\langle m \rangle = 0$ a cualquier temperatura, así que en las simulaciones se trabaja con $\langle |m| \rangle$ como estimador del parámetro de orden, que no sufre la misma simetría.

2.2. Mecánica estadística

En la colectividad canónica, el estado de equilibrio de un sistema en contacto con un baño térmico a temperatura T queda determinado por la función de partición

$$Z = \sum_{\{\sigma\}} e^{-\beta \mathcal{H}(\sigma)},$$

con $\beta = \frac{1}{k_B T}$ y donde la suma se extiende a todos los posibles estados compatibles con el macroestado observado. Esta función contiene toda la información del sistema. Calcularla, ya sea de manera analítica o numérica, es equivalente a resolver el sistema. Esto permite obtener otras cantidades como la energía libre, la capacidad calorífica o la magnetización por partícula.

A partir de Z se define la energía libre $F = -k_B T \ln Z$, de la que se derivan el resto de

magnitudes termodinámicas. La energía media del sistema es

$$\langle E \rangle = -\frac{\partial \ln Z}{\partial \beta},$$

y la capacidad calorífica por partícula se obtiene derivando respecto a la temperatura,

$$c = \frac{1}{N} \frac{\partial \langle E \rangle}{\partial T} = \frac{1}{N k_B T^2} (\langle E^2 \rangle - \langle E \rangle^2), \quad (2.1)$$

expresión que relaciona c con las fluctuaciones de la energía. De forma análoga, la susceptibilidad magnética por espín se relaciona con las fluctuaciones de la magnetización,

$$\chi = \frac{1}{N k_B T} (\langle M^2 \rangle - \langle M \rangle^2),$$

con $M = \sum_i s_i$ la magnetización total. Estas dos expresiones son usadas para calcular c y χ a partir de los promedios medidos sobre las series temporales generadas en las simulaciones.

Otras dos cantidades usadas en este estudio son el cumulante de Binder y la longitud de correlación. El cumulante de Binder de cuarto orden se define como

$$U_4 = 1 - \frac{\langle m^4 \rangle}{3 \langle m^2 \rangle^2},$$

y es una cantidad adimensional que en el límite termodinámico toma, justo en T_c , un valor universal que depende solo de la dimensionalidad y la simetría del sistema. Esto permite utilizarlo como una herramienta muy conveniente para localizar la temperatura crítica usando un sistema finito, como se explica en la sección de escalado de tamaño finito.

La longitud de correlación ξ_L mide la distancia típica a la que están correlacionadas las fluctuaciones de espín, y se obtiene a partir de la función de correlación espín-espín $g(r) = \langle s_0 s_r \rangle - \langle s_0 \rangle \langle s_r \rangle$, que lejos de T_c decae de forma aproximadamente exponencial, $g(r) \sim e^{-r/\xi_L}$, para r grande. En una red finita con condiciones de contorno periódicas resulta más práctico trabajar con la llamada longitud de correlación de segundo momento (Cooper et al., 1982; Newman y Barkema, 1999). Esta se construye a partir del factor de estructura, definido como la transformada de Fourier de la función de correlación,

$$\chi(\mathbf{k}) = \frac{1}{N} \left\langle \left| \sum_j s_j e^{i\mathbf{k} \cdot \mathbf{r}_j} \right|^2 \right\rangle, \quad (2.2)$$

donde $\mathbf{r}_j$ es la posición del espín j . Evaluándolo en el vector de onda nulo y en el menor vector de onda no nulo compatible con la red, $k_{\min} = 2\pi/L$, la longitud de correlación de segundo momento se obtiene tras un desarrollo a segundo orden en el momento de la red y despejando (Cooper et al., 1982),

$$\xi_L = \frac{1}{2 \sin(\pi/L)} \sqrt{\frac{\chi(0)}{\chi(k_{\min})} - 1}. \quad (2.3)$$

La ventaja de esta definición es que puede ser fácilmente calculada a partir de las mismas configuraciones de espín generadas para la medida del resto de observables y no requiere un cálculo explícito de $g(r)$ para cada distancia r .

Por último, queda por explicar cómo se calculan los valores esperados $\langle O \rangle$ que aparecen en todas las fórmulas anteriores. Estos son promedios sobre la colectividad canónica, es decir, promedios físicos pesados por el factor de Boltzmann,

$$\langle O \rangle = \frac{1}{Z} \sum_{\{\sigma\}} O(\sigma) e^{-\beta \mathcal{H}(\sigma)},$$

y no promedios temporales sobre una evolución dinámica del sistema. Como sumar sobre los 2^N microestados es inviable, no evaluamos esta suma directamente, sino que recurrimos al muestreo por importancia: el algoritmo de Montecarlo genera una sucesión de configuraciones $\sigma_1, \dots, \sigma_M$ que, una vez alcanzado el equilibrio, están distribuidas según la propia distribución de Boltzmann; el índice que las ordena no es un tiempo físico, sino el número de pasos de Montecarlo. Para que esto sea válido basta con que la cadena de Markov sea ergódica, es decir, cualquier configuración es alcanzable desde cualquier otra, y satisfaga el balance detallado, condiciones que se imponen sobre los tres algoritmos más adelante (sección 3.6). Bajo ellas, se garantiza que el promedio aritmético sobre las configuraciones generadas converge al promedio físico buscado,

$$\langle O \rangle \approx \frac{1}{M} \sum_{t=1}^M O(\sigma_t),$$

donde $\sigma_t = \{s_i\}_t$ es la configuración completa de la red (el conjunto de los valores de todos los espines) en la t -ésima medida tras la termalización y M es el número de medidas tomadas tras la termalización. Esta es la expresión que se aplica en la práctica para obtener $\langle E \rangle$, $\langle |m| \rangle$, c , χ , U_4 y ξ_L a partir de las simulaciones.

2.3. Transición de fase, temperatura crítica y exponentes críticos

En el límite termodinámico, la transición de fase del modelo de Ising bidimensional ocurre exactamente en T_c [ecuación (1.2)], y alrededor de este punto las magnitudes termodinámicas dejan de ser funciones analíticas de la temperatura. En particular, la longitud de correlación diverge siguiendo una ley de potencias:

$$\xi(T) \sim |T - T_c|^{-\nu},$$

y el resto de cantidades exhiben un comportamiento similar, con diferentes exponentes: la magnetización se anula como $m \sim (T_c - T)^\beta$ para $T < T_c$, la susceptibilidad diverge como $\chi \sim |T - T_c|^{-\gamma}$, y la capacidad calorífica se comporta como $c \sim |T - T_c|^{-\alpha}$. En el caso del modelo de Ising bidimensional, esta última divergencia es solo logarítmica, lo que significa que $\alpha = 0$.

Los exponentes ν , β , γ y α se llaman exponentes críticos, y su origen está en el hecho de que justo en T_c la longitud de correlación se hace infinita y el sistema deja de tener una escala de longitud característica propia. De ahí, el comportamiento queda determinado únicamente por la dimensionalidad del sistema y la simetría del parámetro de orden, siendo independiente de los detalles microscópicos del hamiltoniano. Esto es lo que se conoce como universalidad: sistemas físicamente muy diferentes pueden presentar los mismos exponentes críticos siempre que tengan la misma dimensionalidad y simetría del parámetro de orden, lo que los junta en una misma *clase de universalidad* (Wilson, 1974). El modelo

de Ising bidimensional pertenece a su propia clase de universalidad, para la que los valores exactos de los exponentes son conocidos gracias a la solución analítica de Onsager y a las extensiones posteriores de esta (Yang, 1952),

$$\nu = 1, \quad \gamma = \frac{7}{4}.$$

Estos son los valores de referencia que se utilizarán para comparar los resultados obtenidos a partir de la simulación con las predicciones teóricas.

2.4. Escalado de tamaño finito

Las divergencias descritas en la sección anterior solo ocurren en el límite $L \rightarrow \infty$. En un sistema de tamaño finito, la longitud de correlación nunca puede superar el tamaño de la red, por lo que cerca de T_c se satura en un valor del orden de L en lugar de divergir, y todas las magnitudes termodinámicas son funciones suaves y continuas de la temperatura. La técnica de escalado de tamaño finito (*finite-size scaling*, FSS) (Fisher y Barber, 1972) parte de la suposición de que, cuando ξ es del orden de L , la única razón relevante en el problema es L/ξ , y para cada cantidad debe existir una forma de escala que dependa de L y de T únicamente a través de la combinación $(T - T_c)L^{1/\nu}$. Para las magnitudes de interés en este trabajo, esto se traduce en

$$\begin{aligned} \langle |m| \rangle(L, T) &= L^{-\beta/\nu} f_m((T - T_c)L^{1/\nu}), \\ \chi(L, T) &= L^{\gamma/\nu} f_\chi((T - T_c)L^{1/\nu}), \end{aligned} \quad (2.4)$$

$$\xi_L(L, T) = L f_\xi((T - T_c)L^{1/\nu}) \quad (2.5)$$

donde f_m , f_χ y f_ξ son funciones universales dentro de cada clase de universalidad. Una consecuencia práctica de estas relaciones es que al representar $\langle |m| \rangle L^{\beta/\nu}$ o $\chi L^{-\gamma/\nu}$ frente a $(T - T_c)L^{1/\nu}$ para diferentes tamaños de red, todas las curvas deben colapsar en una única curva universal, siempre que los exponentes y T_c utilizados sean los correctos. Esta es una de las formas más directas de verificar si los exponentes obtenidos son compatibles con los valores teóricos para la clase de universalidad del modelo de Ising bidimensional.

Otra consecuencia del tamaño finito en la simulación es que el máximo de magnitudes como χ o c no se sitúa exactamente en T_c , sino en una temperatura pseudocrítica $T_c(L)$ que depende del tamaño de la red y que converge hacia T_c a medida que L crece, según (Fisher y Barber, 1972)

$$T_c(L) - T_c \sim L^{-1/\nu}.$$

El cumulante de Binder $U_4 = 1 - \frac{\langle m^4 \rangle}{3\langle m^2 \rangle^2}$ (Binder, 1981) es muy útil en esta situación, ya que no tiene dimensiones, por lo que no tiene ningún factor adicional de L en su forma de escala: $U_4(L, T) = f_U((T - T_c)L^{1/\nu})$. Esta propiedad implica que en $T = T_c$ el valor de U_4 es independiente de L , y por tanto las curvas $U_4(T)$ obtenidas para distintos tamaños deben cruzarse todas en el mismo punto, y este punto puede utilizarse para determinar T_c sin necesidad de ningún otro exponente.

2.5. Tiempo de correlación

Conviene precisar primero qué se entiende aquí por tiempo. Una simulación de Monte-carlo no reproduce la evolución dinámica real del sistema, sino que las configuraciones se

obtienen aplicando una regla de actualización estocástica. Por tanto, no existe un tiempo físico, ya que el recorrido se está realizando sobre una serie de configuraciones del espacio físico. Lo que se llama tiempo es sencillamente el índice que ordena la sucesión de configuraciones, medido en pasos Montecarlo (sección 3.2). Es una propiedad discreta, adimensional e intrínseca al algoritmo. En lo que sigue, se entiende por tanto cualquier escala temporal en pasos Montecarlo.

Estos algoritmos generan una sucesión de configuraciones $\sigma_1, \sigma_2, \dots, \sigma_M$ que no son estadísticamente independientes entre sí, ya que cada una se obtiene a partir de la anterior mediante pequeñas modificaciones. La correlación entre configuraciones consecutivas se mide a partir de la función de autocorrelación para una cantidad O (Landau y Binder, 2014),

$$C_O(t) = \langle O(t_0) O(t_0 + t) \rangle - \langle O \rangle^2,$$

que típicamente decae de forma exponencial, $C_O(t) \sim e^{-t/\tau_O}$, donde τ_O es el tiempo de correlación asociado a O . Cuanto mayor es τ_O , más pasos de Montecarlo hay que esperar entre dos medidas para que puedan considerarse independientes, y por tanto mayor es el error estadístico real de una media calculada con un número dado de configuraciones: el número efectivo de medidas independientes es del orden de $M/(2\tau_O)$ en lugar de M .

Cerca de la temperatura crítica, donde ξ crece, el tiempo de correlación también crece. Esto se conoce como ralentización crítica (*critical slowing down*), y está descrito por el exponente dinámico z (Hohenberg y Halperin, 1977),

$$\tau \sim \xi^z \sim L^z.$$

A diferencia de los exponentes estáticos ν , β o γ , el exponente z no depende solo de la clase de universalidad del sistema, sino también del algoritmo empleado para generar la dinámica. Los algoritmos de actualización local, como Metropolis o Glauber, tienen para el Ising 2D un exponente dinámico relativamente grande, $z \approx 2,17$, lo que hace que cerca de T_c el número de pasos necesarios para obtener medidas independientes crezca muy rápidamente con L . Los algoritmos de tipo *cúmulo* (Swendsen y Wang, 1987), como el de Wolff, fueron ideados para evitar o mitigar el ralentizamiento crítico y presentan valores de z cercanos a cero para el modelo de Ising bidimensional. Esta diferencia en el comportamiento de τ con L cerca del punto crítico es uno de los aspectos principales que se comparan en este trabajo entre los tres algoritmos implementados.

En la práctica, los tiempos de correlación se calculan a partir de las series temporales generadas por la simulación. Para una magnitud O , se calcula la función de autocorrelación normalizada

$$\rho_O(t) = \frac{C_O(t)}{C_O(0)},$$

que decae de 1 a 0 a medida que t aumenta. A partir de ella se define el tiempo de autocorrelación integrado,

$$\tau_{\text{int},O} = \frac{1}{2} + \sum_{t=1}^{\infty} \rho_O(t), \quad (2.6)$$

que es la cantidad que determina el error estadístico real de la media $\langle O \rangle$: si las M medidas no fueran independientes sino que estuvieran correlacionadas con tiempo $\tau_{\text{int},O}$, la varianza del estimador de la media sería (Wolff, 2004)

$$\sigma^2(\langle O \rangle) \approx \frac{2\tau_{\text{int},O}}{M} \text{Var}(O).$$

En la suma que define $\tau_{\text{int},O}$ no se puede llegar hasta infinito con datos finitos, ya que para t grande $\rho_O(t)$ se vuelve ruidosa. En la práctica se trunca la suma en algún tiempo t^* a partir del cual $\rho_O(t)$ ha decaído suficientemente, lo que requiere un cierto cuidado para no subestimar $\tau_{\text{int},O}$ truncando demasiado pronto ni sobreestimarlos acumulando ruido al truncar demasiado tarde.

Capítulo 3

Modelo y métodos

3.1. El modelo simulado

El modelo con el que trabajamos es el de Ising bidimensional sobre una red cuadrada de $N = L \times L$ espines, con condiciones de contorno periódicas en las dos direcciones. Los espines toman valores $\sigma_i = \pm 1$ y el hamiltoniano es el de la ecuación (1.1), con un acoplamiento $J = 1$ entre primeros vecinos y sin campo magnético externo ($H = 0$). Fijamos también la constante de Boltzmann a $k_B = 1$. Resulta entonces natural trabajar con la temperatura reducida, adimensional,

$$T^* = \frac{k_B T}{J},$$

que con nuestra elección $J = k_B = 1$ coincide numéricamente con T . Para aligerar la notación omitiremos el asterisco a partir de aquí y escribiremos simplemente T para referirnos a esta temperatura reducida. Con esta convención, la temperatura crítica exacta de Onsager Onsager (1944) es $T_c \approx 2,2692$.

Los tamaños de red que estudiamos son $L \in \{16, 32, 64, 128\}$, que corresponden a sistemas de 256, 1024, 4096 y 16384 espines. La elección de estos tamaños no es casual. Por una parte, se consigue cubrir un rango de L suficientemente amplio como para poder llevar a cabo un análisis por escalado finito satisfactorio, ya que hay un factor de 8 entre el mayor y menor tamaño; por otra parte, tampoco podemos tomar redes demasiado grandes ya que el coste computacional por paso Montecarlo crece como L^2 , y cerca de T_c el número de pasos Montecarlo necesarios para obtener medidas independientes crece también como L^z , por lo que para los algoritmos de Metropolis y Glauber sería irrealizable.

3.2. Definición del paso Montecarlo

Un paso Montecarlo de Metropolis o Glauber consiste en $N = L^2$ intentos de voltear un espín, es decir, uno por cada espín de la red en promedio (el espín que se intenta voltear en cada paso se elige al azar con reemplazamiento, por lo que algunos pueden salir seleccionados más de una vez dentro del mismo paso y otros ninguna). Esta es la definición habitual en la literatura, y tiene la ventaja de que el tiempo queda medido en unidades comparables entre tamaños distintos: un paso Montecarlo son N intentos, o lo que es lo mismo, un intento por espín de media, con lo que la escala temporal es intrínseca al sistema y no crece de forma artificial con L .

En Wolff la definición es más delicada, ya que el tamaño del cúmulo cambia de una

construcción a otra. Seguimos la convención habitual: un paso de Wolff es la construcción de los cúmulos que hacen falta para que la suma acumulada de sus tamaños llegue a N . Así, en promedio, un paso Montecarlo de Wolff gira el mismo número total de espines que uno de Metropolis o Glauber, por lo que las unidades de tiempo son comparables entre los tres algoritmos. En la práctica, el número de cúmulos construidos por paso Montecarlo es inversamente proporcional al tamaño medio del cúmulo: cerca de T_c , donde los cúmulos son grandes, hacen falta pocas; lejos de T_c , donde son pequeños, hacen falta muchas.

3.2.1. Condiciones de contorno

En una simulación numérica, la red tiene un tamaño finito, lo que hace que los espines de los extremos tengan menos vecinos que los de dentro. Para un sistema de $L \times L$ espines, la fracción de espines en el borde es del orden de $1/L$, lo que para redes pequeñas es una fracción no despreciable que puede distorsionar los resultados al romper la homogeneidad del sistema. Para evitar esto se utilizan condiciones de contorno periódicas: los espines del borde derecho de la red se toman como vecinos de los del borde izquierdo, y los del borde superior como vecinos de los del borde inferior, de modo que la red es efectivamente equivalente a un toroide y todos los espines tienen exactamente el mismo número de vecinos. Con esto se elimina el efecto de borde y se recupera la homogeneidad traslacional del sistema, de forma que las únicas desviaciones respecto al límite termodinámico que quedan son las debidas al tamaño finito de la red, que son precisamente las que se estudian mediante el escalado de tamaño finito descrito en la sección 2.4.

3.3. Configuración inicial y termalización

Para cada combinación de tamaño L , temperatura T y algoritmo, la simulación arranca desde una configuración inicial donde todos los espines toman valor $+1$. Esta forma de empezar, conocida como *arranque frío*, es la más natural cuando se barre un rango amplio de temperaturas, ya que así el sistema no corre el riesgo de atascarse en zonas metaestables. Existe también el *arranque caliente* (todos los espines aleatorios, o asignados con probabilidad $1/2$), que converge más rápido en la fase paramagnética pero corre el riesgo de converger en zonas metaestables. En este estudio usamos siempre el arranque frío para prevenir ese tipo de atascos.

Una vez fijada la configuración inicial, hacemos una tanda de pasos de termalización sin tomar ninguna medida, para que el sistema olvide la condición de partida y llegue al equilibrio a la temperatura T correspondiente. El número de pasos Montecarlo de termalización no es el mismo en todo el barrido, sino que sigue la misma división que el vector de temperaturas. En el rango grueso, lejos de la región crítica, los tiempos de autocorrelación de Metropolis y Glauber son pequeños y nos basta con 6000 pasos. En la ventana fina alrededor de T_c aparece el *critical slowing down*: los tiempos crecen como $\sim L^z$, por lo que ahí subimos la termalización hasta 10000 pasos para asegurarnos de que el sistema también llega al equilibrio. Para Wolff no hace falta esta precaución, ya que sus tiempos de correlación son del orden de la unidad en todo el rango, y 6000 pasos Montecarlo son mucho más de los que se necesitan para algoritmos de cúmulo a cualquier temperatura.

L	Ventana fina $[T_{\text{lo}}, T_{\text{hi}}]$	ΔT_{fino}	Rango grueso	ΔT_{grueso}
16	[2,127, 2,695]	$1,418 \times 10^{-2}$	$[0,150, 2,127) \cup (2,695, 5,000]$	0,1
32	[2,198, 2,482]	$7,091 \times 10^{-3}$	$[0,150, 2,198) \cup (2,482, 5,000]$	0,1
64	[2,234, 2,376]	$3,546 \times 10^{-3}$	$[0,150, 2,234) \cup (2,376, 5,000]$	0,1
128	[2,251, 2,322]	$1,773 \times 10^{-3}$	$[0,150, 2,251) \cup (2,322, 5,000]$	0,1

Cuadro 3.1: Ventanas de temperaturas para cada tamaño L , con $T_c = 2,2692$, $T_{\text{lo}} = T_c - T_c/L$ y $T_{\text{hi}} = T_c + 3T_c/L$. La ventana fina contiene siempre 40 subintervalos (41 puntos), independientemente de L .

3.4. Vector de temperaturas

Este recorrido en temperaturas es idéntico para los tres algoritmos y todos los tamaños L , y va de $T = 0,15$ a $T = 5,0$. Lo que cambia dentro de ese intervalo es la resolución: usamos un recorrido adaptativo con dos pasos distintos según lo cerca que estemos del punto crítico.

La pieza central es la ventana crítica $[T_{\text{lo}}, T_{\text{hi}}]$, asimétrica alrededor de T_c , con extremos

$$T_{\text{lo}} = T_c - 1,0 \frac{T_c}{L}, \quad T_{\text{hi}} = T_c + 3,0 \frac{T_c}{L}.$$

Que la anchura escale como T_c/L viene de que la teoría FSS dice que toda la estructura de escala finita (el máximo de χ , el cruce del cumulante de Binder, la inflexión de ξ_L/L) se concentra en una región de anchura relativa $\sim L^{-1/\nu} = L^{-1}$ alrededor de T_c (Newman y Barkema, 1999), es decir, de anchura $\sim T_c/L$ en unidades absolutas; si queremos resolver bien esas estructuras, la ventana fina tiene que escalar igual. La asimetría (un factor 1 por debajo de T_c y un factor 3 por encima) es porque en sistemas finitos el máximo de la susceptibilidad surge en un punto algo mayor que T_c , por lo que conviene dejar más margen por el lado de las temperaturas altas para no perderlo.

Dentro de esa ventana muestreamos con paso fino $\Delta T = 0,1 T_c/L$. Como la anchura es $T_{\text{hi}} - T_{\text{lo}} = 4 T_c/L$ y el paso es $0,1 T_c/L$, la zona fina se divide siempre en 40 subintervalos, independientes de L : tanto la anchura como el paso escalan con T_c/L , así que el número de puntos no cambia con el tamaño. Fuera de la ventana, en $[0,15, T_{\text{lo}}]$ y en $(T_{\text{hi}}, 5,0]$, usamos un paso grueso uniforme $\Delta T = 0,1$, que es más que suficiente para describir el comportamiento general de las magnitudes lejos de la región crítica.

3.5. Parámetros de la simulación

Una vez terminada la termalización, hacemos $N_{\text{steps}} = 1,99 \cdot 10^6$ pasos Montecarlo de medida para cada temperatura y tamaño, cantidad que veremos debería ser suficiente para obtener una muestra estadísticamente significativa. No tomamos una muestra en cada paso Montecarlo, sino cada cierto número de ellos, para reducir la correlación entre medidas consecutivas sin tener que almacenar una gran cantidad de datos en memoria. En Metropolis y Glauber muestreamos cada 50 pasos Montecarlo, lo que nos deja $3,98 \cdot 10^4$ medidas por temperatura y tamaño, y en Wolff cada 5 pasos Montecarlo, con lo que obtenemos $3,98 \cdot 10^5$ medidas por temperatura y tamaño.

Elegimos esta frecuencia de muestreo a partir del tiempo de autocorrelación que se espera fuera de la región crítica, donde τ_{int} es del orden de unos pocos pasos Montecarlo para Metropolis y Glauber. Muestrear cada 50 pasos Montecarlo asegura que las medidas están

suficientemente descorrelacionadas en casi todo el rango de temperaturas. El problema aparece cerca de T_c : para los tamaños mayores los tiempos de correlación se van por encima de 50 pasos Montecarlo, por lo que las medidas siguen estando correlacionadas entre sí. Esto no introduce ningún sesgo en los valores medios, pero sí hace que el error estadístico real sea mayor que el que saldría si tuviéramos muestras independientes, pero sale del alcance de este trabajo el realizar simulaciones con tantos pasos.

En Wolff, el intervalo de 5 pasos Montecarlo vale para todo el rango de temperaturas porque, como ya hemos visto, su τ_{int} es del orden de la unidad incluso cerca de T_c .

3.6. Métodos de Montecarlo

Calcular el valor exacto de Z implica hacer un sumatorio sobre los 2^N microestados del sistema, un cálculo impracticable salvo para redes de dimensiones ridículamente pequeñas. Los métodos de Montecarlo evitan este problema generando, mediante una cadena de Markov, una sucesión de configuraciones cuya distribución de probabilidad converge a la distribución de Boltzmann $P(\sigma) = e^{-\beta\mathcal{H}(\sigma)}/Z$, de forma que se priorice la visita a los estados que más contribuyen a los promedios térmicos en lugar de realizar un recorrido exhaustivo por todos los microestados compatibles con el macroestado y luego pesarlos por su peso de Boltzmann. Esto es lo que se conoce como muestreo por importancia (*importance sampling*) (Metropolis et al., 1953; Sokal, 1997).

Para que el proceso de Markov converja a la distribución correcta, basta con imponer que las probabilidades de transición $W(\sigma \rightarrow \sigma')$ entre dos configuraciones satisfagan la condición de balance detallado,

$$P(\sigma) W(\sigma \rightarrow \sigma') = P(\sigma') W(\sigma' \rightarrow \sigma),$$

y la condición de ergodicidad, según la cual cualquier configuración es alcanzable desde cualquier otra en un número finito de pasos. Los tres algoritmos que se describen a continuación difieren en cómo eligen las configuraciones candidatas σ' y en cómo definen $W(\sigma \rightarrow \sigma')$, pero los tres satisfacen ambas condiciones.

3.6.1. Algoritmo de Metropolis

El algoritmo de Metropolis (Metropolis et al., 1953) propone cambios locales de un solo espín. Partiendo de una configuración σ , se elige un espín i al azar y se calcula la variación de energía ΔE que resultaría de invertir su signo, $s_i \rightarrow -s_i$, manteniendo el resto de la red fija. La nueva configuración se acepta con probabilidad

$$W(\sigma \rightarrow \sigma') = \min(1, e^{-\beta\Delta E}).$$

Si $\Delta E \leq 0$ el cambio se acepta siempre; si $\Delta E > 0$ se acepta con probabilidad $e^{-\beta\Delta E}$, lo que en la práctica se implementa generando un número aleatorio uniforme en $[0, 1]$ y comparando. Si la propuesta no se acepta, la configuración no cambia y de cualquier forma se contabiliza un paso de Montecarlo. Esta regla cumple la condición de balance detallado porque la razón $W(\sigma \rightarrow \sigma')/W(\sigma' \rightarrow \sigma)$ es siempre igual a $e^{-\beta\Delta E} = P(\sigma')/P(\sigma)$, independientemente de cuál de las dos probabilidades sea la que se trunca a 1.

Para la red cuadrada bidimensional, ΔE solo puede tomar cinco valores, según el número de vecinos alineados con el espín cuya inversión se propone, de modo que las probabilidades de aceptación $e^{-\beta\Delta E}$ pueden precalcularse antes del inicio de la simulación en

lugar de hacerlo en cada paso, lo que representa una disminución apreciable del coste computacional ya que se hacen muchas menos operaciones de coma flotante.

3.6.2. Dinámica de Glauber

La dinámica de Glauber (Glauber, 1963) es también un algoritmo de actualización de un solo espín, pero con una regla de transición distinta. En lugar de proponer una inversión y decidir si se acepta o no, en cada paso se calcula directamente la probabilidad de que el espín i tome el valor $+1$ o el valor -1 dadas las orientaciones de sus vecinos, y se asigna uno de los dos valores de acuerdo con esas probabilidades, sin importar cuál fuera el valor anterior del espín. Si E_i^+ y E_i^- son las energías del sistema con $s_i = +1$ y $s_i = -1$ respectivamente, la probabilidad de que el espín quede en el estado $+1$ es

$$p_i^+ = \frac{e^{-\beta E_i^+}}{e^{-\beta E_i^+} + e^{-\beta E_i^-}},$$

y la de que quede en el estado -1 es $1 - p_i^+$. Esta regla también satisface el balance detallado, y da lugar a la misma distribución de equilibrio que el algoritmo de Metropolis.

La diferencia entre ambos radica en la dinámica: en Glauber el nuevo estado del espín se decide de forma independiente del estado anterior, mientras que en Metropolis depende de la anterior por el hecho de que el cambio sólo se acepta bajo una determinada condición. Sin embargo, ambos algoritmos pertenecen a la categoría general de algoritmos de actualización local y comparten el mismo exponente dinámico z , por lo que presentan comportamientos cerca de T_c cualitativamente similares.

3.6.3. Algoritmo de Wolff

El algoritmo de Wolff (Wolff, 1989) pertenece a una familia distinta, los algoritmos de *cúmulo*, diseñados para reducir el tiempo de correlación cerca de T_c . En lugar de actualizar un espín a la vez, en cada paso se construye un agrupamiento de espines vecinos con la misma orientación y se invierte el agrupamiento completo de una sola vez.

El procedimiento es el siguiente. Se elige un espín al azar, que forma la semilla del cúmulo, y se examinan sus vecinos: cada vecino que tenga la misma orientación que la semilla se añade al cúmulo con probabilidad

$$p_{\text{add}} = 1 - e^{-2\beta J}.$$

Cada espín que se incorpora al cúmulo se examina a su vez de la misma manera, de modo que el cúmulo va creciendo hasta que no quedan vecinos que añadir. Una vez completado, todos los espines del cúmulo se invierten simultáneamente. Puede demostrarse que esta probabilidad de aceptación garantiza el balance detallado para el movimiento global de inversión del cúmulo, y por tanto la distribución de equilibrio que se obtiene es la misma que con los otros dos algoritmos.

La ventaja del algoritmo de Wolff es que cerca de T_c , donde los algoritmos locales se quedan atascados en regiones del espacio de configuraciones muy correlacionadas entre sí, el tamaño promedio de los cúmulos crece de modo que cada actualización afecta a una fracción significativa de la red, reduciendo considerablemente el tiempo de correlación. El exponente dinámico z es por tanto mucho menor que el de Metropolis o Glauber, y esta es la razón principal por la que se incluye este algoritmo en la comparativa: permite estudiar el sistema cerca del punto crítico con un coste computacional muy inferior para

los tamaños de red utilizados en este trabajo.

3.7. Observables medidos

Cada paso que toque medir, guardamos las siguientes cantidades usando la configuración instantánea del sistema:

- La energía total del sistema, $E = \mathcal{H}$.
- La magnetización por espín con signo, $m = \frac{1}{N} \sum_i \sigma_i$.
- m^2 y m^4 , necesarios para calcular χ y U_4 .
- El factor de estructura en el vector de onda mínimo, $\chi(k_{\min})$, necesario para calcular ξ_L .

Cuando todas las medidas a una temperatura dada son completadas, se calculan los valores medios de cada magnitud y esto es lo que se guarda. Luego, se hace un procesamiento de datos para generar los observables buscados y sus representaciones gráficas. Estos observables son los siguientes:

La **magnetización media por espín** se define como $\langle |m| \rangle$, es decir, la media del valor absoluto de la magnetización por espín. En un sistema finito la simetría del hamiltoniano hace que la magnetización fluctúe de signo incluso por debajo de la temperatura crítica, por lo que $\langle m \rangle \approx 0$ y esto hace necesario el usar el valor absoluto para obtener un resultado que nos aporte información, obteniendo un valor no nulo para el parámetro de orden del sistema.

La **capacidad calorífica** por espín la calculamos con las fluctuaciones en energía,

$$C = \frac{\beta^2}{N} (\langle E^2 \rangle - \langle E \rangle^2),$$

que es la expresión de la ecuación (2.1). Es el estimador más eficiente para una simulación de Monte Carlo, ya que $\langle E^2 \rangle$ y $\langle E \rangle$ se acumulan en la misma pasada de medidas, sin ningún cálculo extra.

La **susceptibilidad magnética** por espín la sacamos del estimador de fluctuaciones análogo,

$$\chi = \frac{L^2}{T} (\langle m^2 \rangle - \langle |m| \rangle^2),$$

donde hemos usado que $\beta = 1/T$ (con $k_B = 1$) y que $M = Nm$, por lo que $\chi = \beta(\langle M^2 \rangle - \langle M \rangle^2)/N = L^2(\langle m^2 \rangle - \langle |m| \rangle^2)/T$. En la fase desordenada $\langle |m| \rangle \approx 0$, y la expresión se queda en $\chi = L^2 \langle m^2 \rangle / T$.

El **cumulante de Binder** de cuarto orden lo calculamos como

$$U_4 = 1 - \frac{\langle m^4 \rangle}{3\langle m^2 \rangle^2}.$$

En la fase completamente ordenada ($T \rightarrow 0$), donde $|m| \rightarrow 1$ con fluctuaciones pequeñas, se tiene $\langle m^4 \rangle \approx \langle m^2 \rangle^2$ y $U_4 \rightarrow 2/3$. En la completamente desordenada ($T \rightarrow \infty$), donde m sigue una gaussiana centrada en cero, $\langle m^4 \rangle = 3\langle m^2 \rangle^2$ y $U_4 \rightarrow 0$. El paso de un valor a otro, junto con el cruce de las curvas de distintos L en T_c que interpolamos usando splines, es lo que usamos para estimar la temperatura crítica con el cumulante de Binder de cuarto orden.

La **longitud de correlación de segundo momento** ξ_L la calculamos usando la ecuación (2.3), que necesita el factor de estructura en el vector de onda mínimo $\mathbf{k}_1 = (2\pi/L, 0)$. Este factor de estructura lo hemos calculado durante las simulaciones en Fortran como

$$\chi(k_{\min}) = \frac{1}{N} \left\langle \left| \sum_j \sigma_j e^{i\mathbf{k}_1 \cdot \mathbf{r}_j} \right|^2 \right\rangle,$$

donde la suma recorre todos los espines de la red. En la práctica, en cada medida acumulamos por separado la parte real y la imaginaria de $\sum_j \sigma_j e^{i\mathbf{k}_1 \cdot \mathbf{r}_j}$, y al final promediamos el cuadrado del módulo y guardamos el resultado por espín.

El **tiempo de autocorrelación integrado** τ_{int} lo calculamos para la serie temporal de la magnetización por espín $|m(t)|$, que es la magnitud más sensible a las correlaciones cerca de T_c ya que es el parámetro de orden. Usamos el estimador de Madras y Sokal descrito en la sección 2.5 [ecuación (2.6)], con la ventana W fijada automáticamente como el primer instante en que $\rho(t) < e^{-t/\tau_{\text{int}}}$, y con τ_{int} calculado de forma iterativa. Conviene tener en cuenta que τ_{int} no es un observable de equilibrio en el mismo sentido que los anteriores, sino una propiedad de la dinámica del algoritmo, y por eso mantenemos su análisis separado del resto en el capítulo 4.

3.8. Análisis de escalado de tamaño finito

De entrada, se busca estimar T_c a partir de los cruces del cumulante de Binder. Para ello, empezamos interpolando la serie de datos de cada L usando splines. Con estos se buscan los cruces dos a dos entre un tamaño y el siguiente, y se representan las temperaturas a las que se encuentran estos cruces frente a $1/L^2$. De aquí, se hace un ajuste lineal, el cual debería cortar el eje de ordenadas a la temperatura T_c . De aquí obtenemos el resultado presentado, habiendo intentado disminuir los efectos de escala finita.

Para el análisis usando el colapso de los datos partimos del valor exacto de Onsager $T_c = 2,2692$ como temperatura crítica de referencia y de los exponentes exactos de la clase de universalidad del modelo de Ising bidimensional: $\nu = 1$, $\gamma/\nu = 7/4$ y $\beta/\nu = 1/8$. Tomamos el valor de referencia, y lo que se hace es tomar la función universal de la susceptibilidad y de la longitud de correlación, representar todos los tamaños juntos e ir ajustando los exponentes hasta que de manera visual se aprecie el colapso de los datos sobre una única curva de manera aproximada.

Trabajamos con la temperatura reducida $t = (T - T_c)/T_c$ y con la variable de escala $x = t L^{1/\nu} = (T - T_c)L/T_c$ (con $\nu = 1$). Buscamos obtener el colapso de la susceptibilidad representando $\chi L^{-\gamma/\nu} = \chi L^{-7/4}$ frente a x : según la ecuación (2.4), todas las curvas de distinto L deberían colapsar. Hacemos lo mismo con ξ_L/L frente a x , que por la ecuación (2.5) también debería colapsar sobre una función universal. En los dos casos miramos el colapso de forma visual, ya que evaluarlo de forma cuantitativa nos obligaría a tener un modelo para la función de escala $\tilde{\chi}(x)$, y eso se sale de lo que pretendemos en este trabajo. Con esta definición, además, la ventana fina de la malla de temperaturas, $[T_c - T_c/L, T_c + 3T_c/L]$, cae justo en el intervalo fijo $x \in [-1, 3]$, obteniendo el mismo rango para todos los tamaños con la misma densidad de puntos.

Capítulo 4

Resultados y discusión

En este capítulo, se recogen los resultados de las simulaciones descritas anteriormente, y se relacionan con las predicciones teóricas realizadas. Para cada observable, se presentan primero sus datos brutos para cada tamaño y algoritmo, y después se realiza el análisis que toque, ya sea cualitativo o FSS. El capítulo termina con la comparación dinámica entre algoritmos usando el tiempo de correlación integrado, que es donde aparecen las diferencias más significativas entre dinámicas locales y de cúmulo, y entre Metropolis y Glauber.

4.1. Capacidad calorífica y magnetización

Las figuras 4.1 y 4.2 muestran c y $\langle |m| \rangle$ frente a T para los tres algoritmos y los cuatro tamaños de red.

Como esperábamos, la magnetización por espín cae de forma suave, no abrupta, desde valores próximos a la unidad hasta prácticamente cero en la fase paramagnética. Este salto, como también se dijo, es más pronunciado cuanto mayor es L , ya que en una red infinita debería ser un salto abrupto y se aproxima a eso al aumentar el tamaño. Los resultados de los tres algoritmos parecen prácticamente idénticos en estas dos magnitudes, por lo que se tiene la confianza de que se ha muestreado correctamente el ensamble para hacer los promedios. En la capacidad calorífica se puede apreciar para los tres algoritmos cómo el máximo se ensancha y se desplaza hacia la derecha de T_c al disminuir L , lo cual es una tendencia coherente con lo predicho por la teoría.

Se puede pensar que podría ser posible el obtener la temperatura crítica al tratar de seguir la divergencia de los máximos sucesivos de la capacidad calorífica hacia T_c . Sin embargo, el hecho de que se trate de una divergencia logarítmica implica que la altura del máximo crece lentamente como un logaritmo, lo que hace que la diferencia entre nuestros puntos más alejados sea ligera y de difícil ajuste. Esta dificultad es bien conocida, y es lo que motiva el uso del cumulante de Binder y de la susceptibilidad para el análisis FSS.

En cuanto al promedio del valor absoluto de la magnetización media por espín, se acerca mucho a la predicción teórica lejos de la temperatura crítica. Cerca de esta, como ya se ha dicho antes el salto no sigue la forma esperada, sino que hace una transición continua a lo largo de una ventana de temperaturas. Sin embargo, sí que se puede observar de manera bastante clara que cuanto mayor es el tamaño del sistema, más abrupto se vuelve el cambio de fase.




Figura 4.1: Capacidad calorífica frente a temperatura para los distintos algoritmos y $L \in \{16, 32, 64, 128\}$. El máximo de c se agudiza y desplaza hacia T_c al aumentar L .




Figura 4.2: Magnetización media frente a temperatura para los distintos algoritmos y $L \in \{16, 32, 64, 128\}$.

4.2. Cumulante de Binder

El cumulante de Binder U_4 es el observable más directo para encontrar la temperatura crítica del sistema: las curvas para distintos L deben cruzarse en T_c para todos los tamaños con el resto de tamaños. En la práctica, por efectos de la escala finita esto no pasa, pero podemos usar el método descrito por ajuste lineal para tratar de extrapolar el resultado obtenido a un tamaño infinito. A continuación, se muestran los resultados obtenidos para el cálculo del cumulante en el entorno de T_c en la figura 4.3, y las rectas de ajuste obtenidas junto con sus temperaturas extrapoladas usando el método descrito.

El valor universal del cumulante en el punto de cruce es, para el modelo de Ising 2D con condiciones de contorno periódicas, aproximadamente $U_4^* \approx 0,61$ (Binder, 1981). Este valor no depende de L en el límite termodinámico y sirve como comprobación adicional: si los cruces de la simulación se producen a un valor similar a este, esto confirma que los datos son coherentes con la clase de universalidad en la que estamos. Si nos fijamos en las figuras, estos se producen precisamente a más o menos ese valor para todos los pares de tamaño y los tres algoritmos, lo que nos indica de nuevo que las simulaciones y las medidas están hechas de manera correcta. En la figura 4.4, se presentan las rectas de ajuste para cada algoritmo junto con su valor de T_c extrapolado.

La corrección de escala finita a la posición del cruce decae como $L^{-1/\nu} = L^{-1}$ para el modelo de Ising bidimensional, de manera que al duplicar L esa corrección sistemática se reduce a la mitad y las estimaciones $T_c(L, 2L)$ deberían acercarse a T_c de forma ordenada. Sin embargo, en las gráficas de Metropolis y Glauber no se aprecia este efecto. Esto se debe a que su tiempo de autocorrelación integrado τ_{int} se dispara mientras que en Wolff no, por lo que el ruido estadístico es mucho mayor en Metropolis y Glauber y apantalla el decaimiento. Así, solo se pueden observar esas mejoras sistemáticas al aumentar L con una tendencia sistemática al usar Wolff, y en Metropolis y Glauber se dispersan sin mostrar esa mejora al aumentar L .

4.3. Susceptibilidad magnética

La figura 4.5 recoge la susceptibilidad χ obtenida para los tres algoritmos a los cuatro tamaños estudiados. Se puede observar de manera muy clara cómo el máximo diverge con L , donde el valor máximo aumenta con L como se esperaba por $\chi_{\text{máx}} \sim L^{\gamma/\nu}$ con $\gamma/\nu = 7/4$. También se puede ver que el máximo se estrecha y se desplaza hacia T_c de manera ligera, conforme con lo que predice la teoría de FSS.

Podemos cuantificar el crecimiento del máximo con L para hacer una comprobación más de que se cumplen las predicciones teóricas. Buscando y extrayendo $\chi_{\text{máx}}(L)$ para cada tamaño, y representándolo en escala logarítmica frente a $\ln L$ lo que esperamos encontrar es que la pendiente de la recta sea $\gamma/\nu = 7/4 = 1,75$. A continuación se presentan los ajustes realizados con las pendientes obtenidas. Esta comprobación es independiente del colapso de datos y constituye una verificación directa de la ley de potencias $\chi_{\text{máx}} \sim L^{\gamma/\nu}$ sin necesidad de reescalar las variables.

4.4. Escalado de tamaño finito de la susceptibilidad

La figura 4.7 muestra el colapso de las funciones de la susceptibilidad magnética χ con los exponentes experimentales encontrados para cada algoritmo aplicando el colapso FSS.

La calidad del colapso no alcanza la calidad deseada en ninguno de los casos. Para Me-




Figura 4.3: Cumulante de Binder para todos los algoritmos y tamaños.




Figura 4.4: Extrapolación de los cruces de U_4 a infinito para cada algoritmo.

metropolis y Glauber, donde el colapso puede parecer mejor aunque más ruidoso para L mayores, ambos colapsos son considerablemente parecidos en tanto que el máximo de ambos algoritmos a los cuatro tamaños cae sobre $x \approx 1$. Sin embargo, cuando observamos el máximo de Wolff, este está bastante desplazado con respecto a estos dos, más o menos sobre $x \approx 1,5$. Dado que Wolff no sufre ralentizamiento crítico cerca de T_c , esta diferencia en valores que deberían ser idénticos nos lleva a pensar que en el proceso de realización de la simulación de Metropolis y Glauber se infravaloró el número de pasos necesarios para realizar medidas no correlacionadas, de ahí la gran diferencia que se aprecia entre Metropolis y Glauber frente a Wolff.

Este hecho refleja que los algoritmos locales fallan cerca de la temperatura crítica incluso cuando se les aplica lo que a priori parecía un número de pasos de termalización suficiente. En la sección 4.6 se discutirá en más detalle los malos resultados obtenidos aquí. Con esta calidad, los exponentes que hemos extraído de los datos no son demasiado precisos para ninguno de los casos.

4.5. Longitud de correlación

La figura 4.8 muestra ξ_L frente a T para cada algoritmo. Los valores son menores que $L/4$ en todas las gráficas para todos los tamaños. Eso es esperable con la definición de segundo momento usada en la fase ordenada, y no indica ningún problema en la simulación porque el ratio entre los máximos de las curvas se mantiene igual al ratio entre L .

Lo importante es el comportamiento del cociente ξ_L/L , que se muestra en la figura 4.9. Las curvas se cruzan alrededor de T_c , de la misma manera que ocurre con el cumulante de Binder pero ahora con otro observable, y lo que coincide son los máximos de estas y no un punto cualquiera. El hecho de que coincidan en valor para la misma T_c para cada algoritmo, nos indica que efectivamente la longitud de correlación escala de manera lineal con el tamaño de la red.

El hecho de que tanto U_4 como ξ_L/L se crucen aproximadamente en el mismo punto es una comprobación no trivial de la coherencia interna de los datos: son dos observables contruidos de forma completamente distinta, uno a partir de momentos de la magnetización y otro a partir del factor de estructura en el espacio de momentos, y sin embargo ambos señalan la misma temperatura como crítica. Que los tres algoritmos den el mismo cruce en las dos magnitudes refuerza la conclusión de que el equilibrio se está muestreando correctamente en todos los casos. Además, podemos hacer un ajuste lineal para encontrar el exponente crítico $1/\nu$, el cual se muestra en la figura 4.10.

Como era esperable, la pendiente obtenida es en todos los casos muy próxima a uno, lo




Figura 4.5: Susceptibilidad magnética χ en función de T para los tres algoritmos y $L \in \{16, 32, 64, 128\}$. La altura del máximo crece como $L^{\gamma/\nu}$.




Figura 4.6: Ajuste lineal para los algoritmos de $\ln \chi_{\text{máx}}$ frente a $\ln L$, y la pendiente obtenida para la recta.

que nos indica que se obtienen valores aproximados $\nu \approx 1$.

4.5.1. Colapso de datos de la longitud de correlación

La figura 4.11 muestra el colapso FSS de ξ_L/L con los valores de ν encontrados buscando el colapso, para cada algoritmo.

El cruce de las curvas ya visible en la figura 4.9 se convierte aquí en el colapso sobre una función común cuando se usa $(T - T_c)L^{1/\nu}$ como variable de escala, confirmando $\nu = 1$ sin necesidad de ajustar ningún parámetro adicional. Aún así, el colapso de ξ_L/L sufre de los mismos problemas que el colapso de la susceptibilidad. Para el colapso, los datos son más ruidosos en Metropolis y Glauber cuanto mayor es L , pero el reescalado se puede hacer de manera más o menos satisfactoria. Sin embargo, para Wolff aunque las curvas son mucho más limpias, se hace imposible el conseguir un colapso satisfactorio para ningún valor del exponente ν .




Figura 4.7: Colapso FSS de χ con exponentes experimentales para cada algoritmo.




Figura 4.8: Longitud de correlación ξ_L frente a T para cada algoritmo y $L \in \{16, 32, 64, 128\}$. Los máximos crecen con L y se desplazan hacia T_c .




Figura 4.9: Longitud de correlación escalada ξ_L/L frente a T para cada algoritmo y $L \in \{16, 32, 64, 128\}$.




Figura 4.10: Ajuste lineal de los puntos de correlación máxima para cada tamaño L frente a L , en escala logarítmica.

4.6. Tiempo de autocorrelación

Las gráficas de la figura 4.12 son quizás las más informativas del trabajo desde el punto de vista de la comparación algorítmica.

Aquí existe una distinción inicial muy relevante. Para Metropolis y Glauber, se observa claramente el ralentizamiento crítico: el máximo en torno a T_c crece con L , y para $L = 128$ son ya muchísimo mayores que para $L = 16$. Es importante distinguir la gran diferencia de tiempo de autocorrelación entre Metropolis y Glauber, donde en Glauber los máximos son consistentemente unas 3/2 veces mayor que en Metropolis. Esto refleja el hecho de que la probabilidad de aceptación de un movimiento en Metropolis es consistentemente mayor que en Glauber, lo que se refleja en un tiempo de autocorrelación significativamente menor. Para Wolff, en cambio, τ_{int} es muy bajo y muy ruidoso en todo el rango con una pequeñísima estructura de máximo en T_c , lo cual es la manifestación directa de que los algoritmos de cúmulo eliminan prácticamente la ralentización crítica.

Este fenómeno es el que se estima responsable de las diferencias entre Wolff y los otros dos al hacer los colapsos. A la hora de hacer una simulación realmente descorrelacionada, este dato implica que para Glauber al simular en T_c debería hacerse tomando una medida cada 9000 pasos, muy por encima de los 50 que se tomaron constantes para todas las temperaturas en Glauber y Metropolis. Eso significa que en el rango más relevante, se tomaron medidas muy correlacionadas entre sí para los tamaños más grandes, por lo que el error estadístico en estas es muy relevante.

Además, usando el tiempo de autocorrelación integrado podemos estimar el exponente dinámico z de cada algoritmo ajustando a una ley de potencias $\tau_{\text{máx}}(L) \sim L^z$ con barras de error suficientemente pequeñas para distinguir $z \approx 2$ de valores cercanos. Con los cuatro tamaños disponibles, la tendencia es claramente creciente para Metropolis y Glauber y consistente con $z \approx 2$, pero un ajuste cuantitativo preciso requeriría tamaños mayores y un número de muestras mayor para reducir las fluctuaciones en la estimación de τ_{int} . Para Wolff, la estimación de z es aún más difícil porque los valores de τ_{int} son del orden de la unidad y el ruido estadístico domina sobre la señal: el valor $z \approx 0,25$ reportado en la literatura (Wolff, 1989) es difícilmente distinguible de $z = 0$ con los datos disponibles, aunque la práctica ausencia de máximo ya es en sí misma una evidencia cualitativa muy clara de la reducción del *critical slowing down*. Desde el punto de vista práctico, la consecuencia más directa de todo esto es que, para los tamaños estudiados en este trabajo, el coste efectivo de obtener una muestra estadísticamente independiente cerca de T_c es varios órdenes de magnitud menor con Wolff que con los otros dos algoritmos. Aún así, la figura 4.13 presenta los resultados obtenidos de realizar estos ajustes, donde se ve que




Figura 4.11: Colapso FSS de ξ_L/L con exponente experimental para cada algoritmo.




Figura 4.12: Tiempo de autocorrelación integrado τ_{int} frente a T para cada algoritmo y $L \in \{16, 32, 64, 128\}$.




Figura 4.13: Ajuste logarítmico para hallar el exponente dinámico del sistema en cada algoritmo.

se aproximan bastante bien al valor teórico.

Capítulo 5

Conclusiones

En este trabajo hemos simulado el modelo de Ising 2D en red cuadrada con contorno periódico, comparando tres algoritmos de Montecarlo (Metropolis, Glauber y Wolff) para $L \in \{16, 32, 64, 128\}$, con un doble objetivo: comprobar que los tres reproducen la física del equilibrio y comparar su comportamiento dinámico. En equilibrio los tres coinciden, como tienen que hacer al muestrear la misma distribución de Boltzmann. La estimación obtenida de T_c por los cruces del cumulante de Binder es compatible con el valor de Onsager (con $U_4^* \approx 0,61$), y el colapso FSS de χ y ξ_L/L con la búsqueda de los exponentes críticos confirma que los datos pertenecen a la clase de universalidad del modelo de Ising bidimensional. La única salvedad aparece cerca de T_c , en las magnitudes más sensibles a la autocorrelación, donde Metropolis y Glauber acusan la ralentización crítica, por lo que la convergencia limpia de T_c con L solo se ve en Wolff y el máximo de la susceptibilidad colapsada se desplaza a $x \approx 1$ en los algoritmos locales, frente a $x \approx 1,5$ en Wolff, que es el valor que tomamos como bueno.

La diferencia de fondo entre los algoritmos está en la dinámica, medida con el tiempo de autocorrelación integrado τ_{int} . Metropolis y Glauber sufren ralentización crítica, con un máximo de τ_{int} que crece con L en torno a T_c de forma consistente con $z \approx 2$; dentro de esa clase, Glauber es algo más lento que Metropolis (un factor entre 1,5 y 2), porque Metropolis acepta los giros con probabilidad mayor o igual que la de Glauber para cada ΔE y descorrelaciona antes, lo cual es un resultado de validez general. Wolff, en cambio, prácticamente elimina la ralentización crítica: su τ_{int} es del orden de la unidad en todo el rango ($z \approx 0,017$), de modo que cerca de T_c conseguir una muestra independiente cuesta varios órdenes de magnitud menos que con los algoritmos locales, una ventaja que se volvería decisiva con redes mayores.

Como continuación natural, sería interesante extender la comparación al Ising en tres dimensiones, donde no hay solución exacta y los exponentes solo se conocen numéricamente ahora que sabemos que el programa con el análisis de datos funciona de manera satisfactoria al comparar los resultados obtenidos con los resultados exactos del modelo de Ising bidimensional.

Conclusions (English)

In this work we have simulated the 2D Ising model on a square lattice with periodic boundaries, comparing three Monte Carlo algorithms (Metropolis, Glauber and Wolff) for $L \in \{16, 32, 64, 128\}$, with a twofold aim: to check that all three reproduce the equilibrium physics and to compare their dynamical behaviour. At equilibrium the three agree, as they must when sampling the same Boltzmann distribution. The estimate of T_c obtained from the Binder cumulant crossings is compatible with Onsager's value (with $U_4^* \approx 0,61$), and the FSS collapse of χ and ξ_L/L through the search for the critical exponents confirms that the data belong to the universality class of the two-dimensional Ising model. The only caveat appears near T_c , in the observables most sensitive to autocorrelation, where Metropolis and Glauber feel the critical slowing down, so that the clean convergence of T_c with L is seen only with Wolff and the peak of the collapsed susceptibility shifts to $x \approx 1$ for the local algorithms, against $x \approx 1,5$ for Wolff, which is the value we take as reliable.

The underlying difference between the algorithms lies in the dynamics, measured through the integrated autocorrelation time τ_{int} . Metropolis and Glauber suffer critical slowing down, with a peak of τ_{int} that grows with L around T_c consistently with $z \approx 2$; within this class, Glauber is somewhat slower than Metropolis (by a factor between 1,5 and 2), because Metropolis accepts the flips with a probability greater than or equal to that of Glauber for every ΔE and decorrelates sooner, which is a general result. Wolff, by contrast, practically eliminates the critical slowing down: its τ_{int} is of unit order over the whole range ($z \approx 0,017$), so that near T_c obtaining an independent sample costs several orders of magnitude less than with the local algorithms, an advantage that would become decisive for larger lattices.

As a natural continuation, it would be interesting to extend the comparison to the Ising model in three dimensions, where there is no exact solution and the exponents are known only numerically, now that we know that the program together with the data analysis works satisfactorily, as shown by comparing the results obtained against the exact results of the two-dimensional Ising model.

Bibliografía

- Binder, K. (1981). Finite size scaling analysis of Ising model block distribution functions. *Zeitschrift für Physik B Condensed Matter*, 43(2):119–140.
- Cooper, F., Freedman, B., y Preston, D. (1982). Solving ϕ_1^4 field theory with Monte Carlo. *Nuclear Physics B*, 210(2):210–228.
- Fisher, M. E. y Barber, M. N. (1972). Scaling theory for finite-size effects in the critical region. *Physical Review Letters*, 28(23):1516–1519.
- Glauber, R. J. (1963). Time-dependent statistics of the Ising model. *Journal of Mathematical Physics*, 4(2):294–307.
- Hohenberg, P. C. y Halperin, B. I. (1977). Theory of dynamic critical phenomena. *Reviews of Modern Physics*, 49(3):435–479.
- Ising, E. (1925). Beitrag zur Theorie des Ferromagnetismus. *Zeitschrift für Physik*, 31(1):253–258.
- Landau, D. P. y Binder, K. (2014). *A Guide to Monte Carlo Simulations in Statistical Physics*. Cambridge University Press, Cambridge, 4 edition.
- Madras, N. y Sokal, A. D. (1988). The pivot algorithm: a highly efficient Monte Carlo method for the self-avoiding walk. *Journal of Statistical Physics*, 50(1–2):109–186.
- Metropolis, N., Rosenbluth, A. W., Rosenbluth, M. N., Teller, A. H., y Teller, E. (1953). Equation of state calculations by fast computing machines. *The Journal of Chemical Physics*, 21(6):1087–1092.
- Newman, M. E. J. y Barkema, G. T. (1999). *Monte Carlo Methods in Statistical Physics*. Oxford University Press, Oxford.
- Onsager, L. (1944). Crystal statistics. I. A two-dimensional model with an order-disorder transition. *Physical Review*, 65(3–4):117–149.
- Peierls, R. (1936). On Ising’s model of ferromagnetism. *Mathematical Proceedings of the Cambridge Philosophical Society*, 32(3):477–481.
- Sokal, A. D. (1997). Monte Carlo methods in statistical mechanics: foundations and new algorithms. En DeWitt-Morette, C., Cartier, P., y Folacci, A., editores, *Functional Integration: Basics and Applications*, pages 131–192. Plenum Press, New York.
- Stanley, H. E. (1971). *Introduction to Phase Transitions and Critical Phenomena*. Oxford University Press, Oxford.
- Swendsen, R. H. y Wang, J.-S. (1987). Nonuniversal critical dynamics in Monte Carlo simulations. *Physical Review Letters*, 58(2):86–88.
- Wilson, K. G. (1974). The renormalization group and the ϵ expansion. *Physics Reports*, 12(2):75–199.

- Wolff, U. (1989). Collective Monte Carlo updating for spin systems. *Physical Review Letters*, 62(4):361–364.
- Wolff, U. (2004). Monte Carlo errors with less errors. *Computer Physics Communications*, 156(2):143–153.
- Yang, C.-N. (1952). The spontaneous magnetization of a two-dimensional Ising model. *Physical Review*, 85(5):808–816.